

OfferDesk

AI-квалификатор лидов для ИЖС

Павел Кофф · 02.10.2026


Модель структурирует, код решает

Дашборд

Сделки в работе
5
из 5 всего

Средний чек (ТК)
10 598 769 Р
по сделкам с площадью

Воронка: звонок → КП → отправка



Новые сделки



Новые
2

Неполные
0

КП готово
2

Последние сделки

ID	Клиент	Телефон	Email	Telegram	Участок	Стоимость ТК
7	Дмитрий	+79164443322	dmitry_b@inbox.ru	⊗ Нужно уточнить	8 соток	13 145 075 Р
1	Сергей	+7 (916) 123-45-67	pkarikov@yandex.ru	@RadomirRossich	12 соток, Московская область (6 соток под застройку)	11 250 000 Р
2	Мария	+7 903 555-12-34	maria.ivanova@yandex.ru	⊗ Нужно уточнить	⊗ Нужно уточнить	8 250 000 Р
3	Алексей	+7 926 777-88-99	alexei.smirnov@gmail.com	⊗ Нужно уточнить	8 соток рядом с Истрой	9 750 000 Р
4	Ольга	⊗ Нужно уточнить	⊗ Нужно уточнить	⊗ Нужно уточнить	⊗ Нужно уточнить	—

Отдел продаж ИЖС теряет лиды

СКОРОСТЬ РЕАКЦИИ

30–40%

лидов уходят из-за медленного ответа. Норма — 15 минут, факт — часы.

РУЧНОЕ КП

40–60 мин

на подготовку одного коммерческого предложения вручную.

REGEX ТЕРЯЕТ КЛЮЧЕВЫЕ ПОЛЯ

budget_rub	recall 0.00
start_date	recall 0.30
financing	recall 0.50

НЕТ КОНТРОЛЯ КАЧЕСТВА

заглушки?

Где реальные данные, где пустые поля — менеджер не видит. Заявка может быть молча испорчена.

Один pipeline — два входа

Заявка

сайт / Авито / Циан

POST /ingest JSON

Звонок

форма CRM

/deals/new

extraction.pipeline.extract()

LLM → JSON → DealExtraction → merge с regex

validate

бюджет, площадь, форматы

escalate

legal_risk · llm_failed · ...

score

лид А / В / С

audit_log


пишется всегда

CRM-сделка + inbox-контракт action

intent / priority / next_action — считает код, не модель

«Модель структурирует, код решает».

Архитектура extraction/



9 слоёв, единая точка `pipeline.extract()`, контур отказа через `regex-fallback`.

9 СЛОЁВ

schema	DealExtraction, etalon_score
llm_extractor	structured output, промпт v1/v2
regex_fallback	контур отказа, 53.3% exact
pipeline	единственная точка <code>extract()</code>
validation	бюджет, площадь, форматы
escalation	legal_risk, llm_failed, ...
scoring	$A \geq 0.7 \cdot B \geq 0.4 \cdot C$
actions	inbox-контракт — считает код
audit	пишется всегда

Разделение ответственности

LLM СТРУКТУРИРУЕТ

DealExtraction — JSON Schema + Pydantic

- бюджет, площадь, срок, участок
- финансирование, материал, контакты
- sentiment / tone / objections
- confidence по полям

Температура извлечения 0.2. Модель не ставит цену и не выбирает next_action.

КОД РЕШАЕТ

validate → escalate → score → action

- intent — quote / qualify / escalate / reject
- priority — low / medium / high
- next_action — что делать менеджеру
- escalate — bool, считает код

Envelope собирается поверх схемы. LLM не может переопределить маршрут.

priority и **escalate** считает код, не LLM. Модель не может «замолчать» юридический риск или провал валидации.

Контроль качества

слой	ЧТО ДЕЛАЕТ
Валидация	Бюджет ≥ 3 млн, площадь 50–500 м², форматы телефона и email
Эскалация	legal_risk, validation_failed, low_confidence (LLM), llm_failed, insufficient_data
Actions	intent / priority / next_action / confidence (enum) / escalate
Аудит	input_text + result_json + status ∈ {success, escalated, error}
Безопасный выход	При падении LLM: HTTP 200 + envelope с intent=escalate

Сделка #8

Неполные данные

Основное

КП

История 1

Файлы 1

Заполнение данных (эталон)

regex лид С

71%

Прод · сделка #8 · regex · лид С · эталон 71%

Сделка #9

Неполные данные

Основное

КП

История 1

Файлы 1

Заполнение данных (эталон)

regex лид С эскалация

43%

Прод · сделка #9 · эскалация · эталон 43%

Заявка не может быть молча проглочена — audit_log пишется всегда.

Lead scoring

ФАКТОРЫ

Бюджет ≥ 3 млн		0.25
Срок старта		0.15
Участок		0.15
Нет возражений		0.15
Позитив		0.15
Decision maker		0.15

Сумма весов = 1.00. Считает код поверх DealExtraction, не модель.

ГОРЯЧИЙ

A
≥ 0.7

ТЁПЛЫЙ

B
≥ 0.4

ХОЛОДНЫЙ

C
< 0.4

Лид А без эскалации → priority=high.
Эскалация любого грейда → тоже high: юрист и
руководитель ОП важнее сора.


Метрики: regex → LLM v1 → LLM v2



ПОЛЕ	REGEX	LLM V1	LLM V2
budget_rub	0.00	0.91	1.00
start_date	0.30	0.90	1.00
financing	0.50	1.00	1.00
area_m2	0.54	0.85	1.00
sentiment	0.00	0.71	1.00
phone	1.00	0.07	1.00
tone	0.00	0.93	0.93

Golden set: 15 кейсов. Промпт-итерация v1 → v2. Regex не достаёт бюджет ни разу. v1 закрыл бюджет, но сломал телефон. v2 с few-shot починил телефон и защитил схему от null — 12 через LLM, 3 через merge, ни одного fallback.

Окупаемость: от 1 недели до 1 месяца



Ограничения и что мы честно признаём

СЕЙЧАС: LLM V2

OpenAI доступен, промпт v2. Golden set — **100% exact** (15/15). Regex — не основной режим.

КОНТУР ОТКАЗА

Если API недоступен → regex fallback, **53.3% exact**. Процесс не падает, в audit_log пишется llm_failed.

ТАЙМАУТ

timeout=35, max_retries=0 → APITimeoutError → fallback за 35 сек, процесс не падает.

REGEX CONFIDENCE

Не эскалируем по confidence=0.3 — шум канала. Мало данных: etalon<30 → insufficient_data.

ЦЕНА НЕ У LLM

Модель только структурирует. Цена и юридическая ответственность — у менеджера и прайса компании.

CREATIVE-ШАГ

Черновик ответа 0.7–0.9 — roadmap. Сейчас chat_json фиксирован на 0.2: температура извлечения, не текста.

Один код, три режима: llm / regex / merged.

Что дальше

1 Tone 0.93 → 0.95 — доп. few-shot

2 Интеграция с Битрикс24 / amoCRM

3 Интеграция с 1С — прайс-листы

4 Дашборд качества в реальном времени

5 Отдельный creative-шаг (temperature 0.7)

6 NL-прокси на VPS как запасной канал, не как единственный

Основной режим — `llm (v2)`. Тот же `pipeline.extract()` при сбое API уходит в `regex`, при низкой уверенности — в `merge`. Архитектуру менять не нужно.

AI-квалификатор лидов для ИЖС

КОМУ

Строительные компании с отделом продаж 3–20 человек.

ЧТО

AI-слой поверх CRM, не замена. Транскрибация → JSON → валидация → эскалация → scoring → аудит.

ПИЛОТ

50 заявок

бесплатно, на ваших данных

ОКУПАЕМОСТЬ

от 1 недели

при чеке 8 млн ₽

КОНТАКТЫ

Павел Кофф

GitHub

github.com/PavelKoff2025/OfferDesk

Прод

<http://194.67.103.144:5001>

Release

v1.1.0

Спасибо! Вопросы?